


1. Motivacao e Contexto

1.1 O que e o Olist

O **Olist** e um marketplace brasileiro que funciona como **intermediario** entre **pequenos e medios vendedores (SMEs)** e **grandes plataformas de e-commerce**. Em vez de cada vendedor se registrar individualmente na Amazon, na Worten, na FNAC e no El Corte Ingles online (o equivalente brasileiro dessas plataformas), o Olist faz isso por eles com um unico contrato, colocando os produtos em todos os marketplaces em simultaneo.



O negocio do Olist baseia-se em **comissoes por venda**. Cada vez que um vendedor concretiza uma encomenda atraves da plataforma, o Olist retira uma percentagem. Isto cria um interesse direto: **se os vendedores vendem menos, o Olist recebe menos**. **E os vendedores vendem menos quando tem avaliacoes negativas**. E por isso que o Olist tem incentivo financeiro em resolver o problema da satisfacao do cliente.


1.2 O Olist e a Logistica

O Olist **nao trata dos transportes diretamente**. A responsabilidade logistica pertence ao vendedor, que envia a encomenda através de uma transportadora parceira externa. O Olist e apenas o intermediario comercial. Quando ha um atraso, pode ter duas origens distintas: o vendedor demorou a preparar e entregar a transportadora, ou a transportadora demorou a entregar ao cliente. O nosso dataset nao permite distinguir qual das duas causou o atraso - conhecemos apenas o resultado final. Esta e uma **limitacao a mencionar se o professor perguntar**.

1.3 O Ciclo do Problema

O problema central e um **ciclo vicioso**: atrasos na entrega geram insatisfacao, que se traduz em avaliacoes negativas (1 ou 2 estrelas), que penalizam o ranking dos vendedores nos marketplaces, o que leva a menos vendas, reduzindo as comissoes do Olist. Eventualmente, os vendedores insatisfeitos abandonam a plataforma e o Olist perde receita e credibilidade.

O nosso projeto quebra este ciclo em tres frentes: **identifica** onde e quando acontece (DW + OLAP), **explica** o que o causa (diagnostico estatistico) e **antecipa** quando vai acontecer para agir antes (Data Mining).



1.4 O Utilizador-Alvo: Sebastiao M., Ops Manager

Quem usa os nossos dashboards?

Os dashboards são destinados a **colaboradores operacionais do Olist** como o Sebastiao M., Ops Manager. Ele é responsável por garantir que as encomendas são entregues a tempo e que os vendedores mantem boa reputação. No dia-a-dia precisa de perceber rapidamente se existem problemas de entrega, em que regioes estao a acontecer, quais os vendedores com pior performance e se existe risco de picos de insatisfação.

Sem o nosso sistema, o Sebastiao teria de consultar multiplas fontes de dados manualmente, sem qualquer forma de antecipar problemas. Com os nossos dashboards, consegue numa unica plataforma **ver tendências em tempo real, filtrar por estado ou periodo, identificar vendedores problematicos e receber alertas automaticos sobre encomendas em risco antes que o cliente seja afetado**.

1.5 O Pitch para o Investidor

Perspetiva nao tecnica - como vender esta ideia

O enunciado pede explicitamente para pensar na apresentacao como uma **pitch para um investidor ou stakeholder**. A mensagem central deve ser: "Cada review negativa que o Olist consegue evitar representa revenue protegido. O nosso sistema transforma dados existentes num mecanismo de prevencao proativa - sem custos de infraestrutura adicionais, usando dados que ja existem, com um dashboard que qualquer gestor operacional consegue usar no dia-a-dia."

Argumento de valor em numeros (estimativa para apresentacao):

Se **6.4%** das encomendas chegam atrasadas e 62% dessas geram review negativa, e o revenue em risco e **RS811K** (como mostra o dashboard Delivery Performance) - mesmo reduzir os atrasos em 20% protegeria **~RS162K de revenue**. Este e o valor de negocio do sistema.

2. Os Dados

2.1 Data Warehouse vs Base de Dados Normal

Um **Data Warehouse (DW)** e uma base de dados desenhada especificamente para **analise**, ao contrario de uma base de dados normal que e otimizada para **registar transacoes**. Os 9 CSVs do Olist sao a base de dados normal - registam o que aconteceu encomenda a encomenda. O DW que construímos em PostgreSQL transforma esses dados numa estrutura que permite responder as 6 Big Questions de forma eficiente. O DW e tambem chamado de **single source of truth** - uma fonte centralizada e fiavel para todas as analises.

Base de Dados Normal (OLTP)
Objetivo: guardar transacoes rapidamente.
Estrutura: muitas tabelas normalizadas. Query tipica: inserir nova encomenda. Otimizado para escrita. Sofre com queries analiticas complexas.

Data Warehouse (OLAP)
Objetivo: analisar e responder a perguntas de negocio.
Estrutura: star schema (simples e rapido). Query tipica: qual o atraso medio por estado em 2017? Otimizado para leitura e agregacao.

2.2 As 9 Tabelas de Origem

O dataset do Olist tem 9 tabelas CSV com ~100K encomendas reais entre 2016 e 2018, cobrindo 27 estados brasileiros.

Tabela	O que representa	Campos-chave relevantes
olist_orders	A encomenda em si - status e todas as datas	order_id, order_status, datas de compra/entrega/estimativa
olist_order_items	Os produtos dentro de cada encomenda	order_id, product_id, seller_id, price, freight_value
olist_customers	Quem comprou (sem dados pessoais identificaveis)	customer_id, zip_code, city, state
olist_sellers	Quem vendeu	seller_id, zip_code, city, state
olist_products	O produto em si	product_id, category_name, weight_g, dimensoes
olist_order_reviews	A avaliacao do cliente apos entrega	order_id, review_score (1-5), comentario, data
olist_order_payments	Como o cliente pagou	order_id, payment_type, installments, payment_value
olist_geolocation	Coordenadas geograficas por zip code	zip_code_prefix, latitude, longitude
product_category_name_translation	Traducao de categorias PT -> EN	category_name, category_name_english

2.3 Como as Tabelas se Ligam

A tabela central e a olist_orders, que se liga a quase todas as outras. A ligacao mais importante para o projeto passa por olist_order_items - e ela que conecta uma encomenda ao produto e ao vendedor.



3. As 6 Big Questions

Nota sobre o numero de perguntas: O poster mostra 4 perguntas por questoes de espaço. Na proposta inicial tinhamos 6. A resposta correta se o professor perguntar: Q3 (performance de vendedores) e Q6 (clustering) existem e serão implementadas nos dashboards, mas nao cabiam no formato do poster. As 4 mostradas cobrem todos os tipos pedidos pelo enunciado.

As perguntas cobrem os **4 tipos de analytics** pedidos no enunciado (mais o 5o tipo - decisivo): **Descriptive** (o que aconteceu?), **Diagnostic** (porque aconteceu?), **Predictive** (o que vai acontecer?), **Prescriptive** (o que fazer?) e **Decisive** (que decisao tomar? - Q6 clustering).

Q1 - DESCRIPTIVE

Quais as regioes e categorias com maior volume, atraso e menor review score, e como evoluiram ao longo do tempo?

Esta pergunta descreve o estado atual dos dados. Queremos saber quais estados do Brasil tem mais encomendas e mais atrasos, quais as categorias com pior satisfacao e como estas metricas evoluiram entre 2016 e 2018. A resposta vem de queries OLAP no Tableau com GROUP BY em estado, categoria e data, agregando **COUNT**, **AVG(delay_days)** e **AVG(review_score)**.

Q2 - DIAGNOSTIC

O atraso e os portes estao associados a reviews negativas? Qual o peso relativo de cada fator?

Esta pergunta quantifica o **peso relativo** de cada fator, nao so confirma que ha relacao. Usamos **regressao logistica** com ds_negative_rev como variavel dependente e delay_days + freight_value como preditores. Os coeficientes dizem qual pesa mais. Antes, confirmamos a relacao com **correlacao de Spearman**. Falamos sempre de 'associacao', nunca de 'causa'.

Q3 - DESCRIPTIVE + DIAGNOSTIC (Performance de Vendedores)

Quais os vendedores com melhor e pior desempenho? Que fatores explicam as diferencas?

Q3 combina dois tipos. A parte **descritiva** cria um ranking de vendedores por taxa de atraso e review score medio. A parte **diagnostica** cruza estes resultados com variaveis explicativas: o estado do vendedor, as categorias que vende e o seu volume de encomendas. O objetivo e perceber se um vendedor tem mau desempenho por causa da localizacao geografica (mais longe dos centros logísticos), das categorias que vende (produtos pesados atrasam mais?) ou simplesmente por ter baixo volume.

Q4 - PREDICTIVE

Conseguimos prever uma review negativa antes da entrega, usando apenas dados pre-entrega?

Só podemos usar features que existem **antes da entrega acontecer** (categ. do produto, estado do cliente, seller_id, freight_value, nº de parcelas, dias estimados de entrega, peso do produto), **não podemos usar o delivery_delay_days real** porque ainda nao sabemos quanto vai atrasar.

Usamos **Random Forest ou XGBoost** - robustos com features mistas e interpretativos por feature importance. Como reviews negativas sao ~16% do dataset (class imbalance), avaliamos com **F1-score por ex**

Q5 - PRESCRIPTIVE

Conseguimos estimar o tempo de entrega e gerar alertas preventivos automaticos para encomendas em risco?

Q5 e prescritivo porque nao so preve - **age**. O modelo de regressao estima os dias de entrega. Quando a previsao ultrapassa um threshold (ex: 3 dias de atraso com >70% de probabilidade), o sistema dispara automaticamente uma notificacao ao cliente ou a equipa de suporte. Q4 e **passivo** (devolve score de risco); Q5 e **ativo** (decide e age). Esta e a diferenca que torna Q5 prescritivo.

Q6 - CLUSTERING (Decisive)

Que grupos de encomendas emergem naturalmente nos dados com base em categoria, regioao, vendedor e epoca do ano?

O clustering é não supervisionado - não tem label. O algoritmo (K-Means) descobre sozinho grupos com características semelhantes. Por ex, pode emergir um cluster de encomendas do Norte do Brasil com produtos pesados e vendedores pequenos com perfil de alto risco, distinto de um cluster de Sao Paulo com electronica e

vendedores grandes. E **decisive** porque os clusters informam decisoes estrategicas - por exemplo, direcionar esforcos logísticos para os clusters de maior risco. O numero de clusters sera justificado com **elbow plot** e **silhouette score**.

4. OLAP - Online Analytical Processing

OLAP significa **Online Analytical Processing** - e o conjunto de tecnologias e tecnicas que permitem fazer analise multidimensional de grandes volumes de dados de forma rapida e interativa. E o que o Tableau faz sobre o nosso Data Warehouse em PostgreSQL. Ao contrario de queries SQL simples, o OLAP permite **explorar os dados em multiplas dimensoes simultaneamente** - por estado, por categoria, por periodo, por vendedor - e navegar entre niveis de detalhe de forma fluida.

4.1 ROLAP vs MOLAP vs HOLAP

Ha tres tipos de OLAP, que diferem na forma como os dados sao armazenados e processados. A escolha afeta diretamente a arquitetura do projeto:

Tipo	Como funciona	Vantagens	Desvantagens	Usamos?
ROLAP (Relational)	Modelo multidimensional sobre uma BD relacional (ex: PostgreSQL + Tableau)	Usa infraestrutura existente, escala bem, SQL familiar	Queries complexas podem ser lentas	Sim - o nosso caso
MOLAP (Multidimensional)	Base de dados propria otimizada para arrays multidimensionais (cubos)	Muito rapido para queries pre-agregadas	Rigido, dificil de atualizar, tecnologia quase obsoleta	Nao
HOLAP (Hybrid)	Combina os dois: dados sumarios em MOLAP, dados detalhados em ROLAP	O melhor dos dois mundos	Mais complexo de implementar	Nao

4.2 As 4 Operacoes OLAP

As operacoes OLAP definem como o utilizador navega pelos dados. O Tableau implementa todas estas operacoes atraves de filtros, drill-downs e views. Saber nomear estas operacoes e importante para a apresentacao.

Roll-up (agregar)

Sobe num nivel da hierarquia - agrupa dados mais especificos em menos especificos. Exemplo: passar de **vendas por mes** para **vendas por trimestre** para **vendas por ano**. No nosso dashboard: o filtro temporal faz roll-up quando passamos de Full Period para uma visao anual.

Slice (fatiar)

Fixa uma dimensao num valor especifico, reduzindo o cubo de dados. Exemplo: filtrar por **estado = SP** - obter apenas os dados de Sao Paulo. No nosso dashboard: clicar num estado no mapa e uma operacao slice.

Drill-down (detalhar)

Desce um nivel da hierarquia - do geral para o especifico. Exemplo: clicar numa regioao do Brasil para ver os estados, depois num estado para ver as cidades. E o oposto do roll-up. No nosso dashboard: o mapa clicavel por estado e um drill-down geografico.

Dice (cortar em cubos)

Aplica multiplos filtros simultaneamente em diferentes dimensoes. Exemplo: **estado = SP AND categoria = electronica AND periodo = 2017**. E como fazer um slice em mais do que uma dimensao ao mesmo tempo. No nosso dashboard: usar o filtro de estado + o filtro temporal + o filtro de categoria em conjunto.

4.3 Hierarquias de Atributos

Uma **hierarquia de atributos** define relacoes de nivel entre atributos de uma dimensao - do mais geral para o mais especifico. Estas hierarquias sao o que torna possiveis as operacoes de roll-up e drill-down. A nossa **dim_date** e o exemplo perfeito:

Hierarquia da dim_date:

Ano -> Semestre -> Trimestre -> Mes -> Semana -> Dia -> Hora


Drill-down: Ano -> Semestre -> Trimestre -> Mes -> Dia
Ex: 2017 -> Q4 2017 -> Dezembro 2017 -> 15 Dezembro 2017

Roll-up: Dia -> Mes -> Trimestre -> Ano
Ex: vendas diarias -> vendas mensais -> vendas anuais

A dim_date ja tem estes campos pre-calculados:
full_date, date_year, date_month, date_day, quarter, day_of_week, is_weekend, hour
-> Evita calculos em tempo de query, o que acelera o Tableau.

5. O Workflow Completo

O pipeline do projeto tem 6 etapas, desde os dados brutos ate a decisao de negocio.




5.1 Ferramentas e Justificacoes

Pentaho (ETL) Ferramenta open-source com interface visual para transferir dados entre sistemas e permite automatizar loads incrementais futuros sem reescrever scripts. PostgreSQL (DW) Gratuito, robusto para star schemas, boa integracao com Python. O Olist (~100K ordens). Suporta ROLAP de forma eficiente.	Tableau (OLAP + Dashboards) Dashboards interativos com filtros temporais e geograficos. Liga diretamente ao banco de dados, sem exportacao de dados. Implementa ROLAP de forma transparente. Python / sklearn (Data Mining) Biblioteca completa de ML. SMOTE disponivel para class imbalance. K-Means e DBSCAN num unico ambiente.
--	---

6. O Star Schema

O star schema e a estrutura do nosso Data Warehouse. Tem uma **tabela de factos ao centro** - que regista os eventos que queremos medir - rodeada de **5 tabelas de dimensoes** que fornecem o contexto para filtrar, agrupar e analisar. E chamado 'estrela' porque as dimensoes irradiam a partir do centro.



6.1 Star Schema vs Snowflake Schema

Esta e uma das perguntas mais comuns em provas de DW. O **Snowflake Schema** e uma variante do star schema em que as dimensoes sao **normalizadas** - ou seja, divididas em sub-tabelas para eliminar redundancia. Por exemplo, em vez de dim_customer ter city e state diretamente, teria uma dim_city que liga a uma dim_state.

Star Schema (o que usamos) As dimensoes sao desnormalizadas - todos os atributos numa so tabela. Mais simples, queries mais rapidas (menos JOINs), mais facil de entender e usar no Tableau. <pre>dim_customer sk_customer (PK) customer_id (NK) zip_code</pre>	Snowflake Schema (nao usamos) As dimensoes sao normalizadas - divididas em sub-tabelas. Poupa espaco mas aumenta o tempo de resposta (mais JOINs) e torna as queries mais complexas. <pre>dim_customer sk_customer (PK) customer_id (NK) zip_code</pre>
--	--

<pre>city <- redundante? state <- redundante? latitude longitude</pre> -> Usamos Star porque as dimensoes sao pequenas e a velocidade de query justifica a redundancia.	<pre>sk_city (FK) -> dim_city sk_city (PK) city sk_state -> dim_state</pre> -> Os slides da professora dizem: 'Using snowflakes is rarely justifiable' porque as dimensoes sao sempre uma pequena parte do DW.
--	---

6.2 Surrogate Keys - Porquê sk_*?

Todos os registos nas dimensoes tem uma **surrogate key (SK)** - uma chave artificial gerada pelo proprio DW (sk_customer, sk_seller, etc.). O sistema de origem tem as suas proprias chaves (customer_id, seller_id) - chamadas **natural keys (NK)**. Porquê nao usar as NKs diretamente?

PROBLEMA com natural keys:

Hoje: customer_id = 'abc123'
Amanha: o sistema Olist decide mudar o formato dos IDs -> 'CL-abc123'
-> Todos os registos da fact_sales com esse FK ficam invalidos!

SOLUCAO com surrogate keys:

sk_customer = 1 (gerado pelo DW, nunca muda)
customer_id = 'abc123' (a NK, pode mudar no sistema de origem)
-> A fact_sales referencia sk_customer = 1, que nunca muda
-> Se o sistema de origem mudar o ID, so atualizamos a dim_customer o resto do DW nao e afetado

As surrogate keys tambem permitem implementar SCD Type 2 (manter historico de mudancas) sem conflito, e garantem que o DW funciona mesmo que multiplos sistemas de origem usem os mesmos IDs.

6.3 Granularidade

Pergunta certa: 'Qual a granularidade da fact_sales?' -> Um registro por item de encomenda (order_item).

Isto significa que se uma encomenda tiver 3 produtos de 2 vendedores diferentes, gera 3 linhas na fact_sales. Porquê? Porque assim conseguimos analisar por **categoria de produto (dim_product)** e por **vendedor (dim_seller)** de forma independente. Se a granularidade fosse ao nivel da encomenda, nao conseguiriamos analisar por categoria e vendedor ao mesmo tempo quando ha multiplos itens.

6.4 Factos Aditivos vs Nao-Aditivos

Nem todas as medidas numa fact table sao iguais. As **medidas aditivas** podem ser somadas em qualquer dimensao (ex: price - faz sentido somar o revenue total). As **medidas semi-aditivas** so fazem sentido nalgumas dimensoes (ex: review_score - a media faz sentido, a soma nao). As **medidas nao-aditivas** nunca devem ser somadas (ex: taxas percentuais).

FACT TABLE - Classificacao das medidas:			
price	-> ADITIVA	-> SUM(price) = revenue total	(faz sentido)

freight_value	-> ADITIVA	-> SUM(freight) = total portes (faz sentido)
payment_value	-> ADITIVA	-> SUM(payment) = receita total (faz sentido)
delay_days	-> SEMI-ADIT	-> AVG(delay) = atraso medio (faz sentido)
		-> SUM(delay) = ??? dias totais (nao faz sentido)
review_score	-> SEMI-ADIT	-> AVG(review) = satisfacao (faz sentido)
		-> SUM(review) = ??? pontos (nao faz sentido)

Porquê o review_score esta na dim_order e nao na fact_sales? *(Resposta tecnica completa)*

Ha duas razoes complementares. Primeira: o review_score e **semi-aditivo** - a soma nao tem significado. Isto faz dele mais um atributo de contexto do que uma medida. Segunda: a granularidade da fact_sales e ao nivel do item, mas o review existe ao nivel da encomenda. Uma encomenda com 3 itens teria o mesmo review_score repetido 3 vezes na fact_sales, o que **inflationaria as medias**. Ao colocar o review na dim_order (que tem granularidade de encomenda), garantimos que e contado uma so vez por encomenda.

6.5 A Tabela de Factos (fact_sales)

Campo	Tipo	Origem	Para que serve
sk_sales	Int PK AU	Gerado pelo DW	Chave primaria surrogate
sk_date	Int FK	dim_date	Quando aconteceu (data de compra)
sk_product	Int FK	dim_product	Que produto
sk_customer	Int FK	dim_customer	Quem comprou
sk_seller	Int FK	dim_seller	Quem vendeu
sk_order	Int FK	dim_order	A que encomenda pertence
price	Float	order_items.price	Preco do item - medida aditiva
freight_value	Float	order_items.freight_value	Portes - Q2
payment_type	VChr	order_payments	Tipo de pagamento (cartao, boleto...)
payment_installments	Int	order_payments	Numero de parcelas
actual_delivery_int	Int	Calculado no ETL	Dias reais de entrega (purchase->delivered)
delay_days	Int	Calculado no ETL	delivered - estimated (positivo=atraso)
is_late_delivery	Int	Calculado no ETL	Flag: 1 se delay_days > 0

Nota: **payment_type** e **payment_installments** estao na fact_sales e nao numa dim_payment separada porque sao atributos da transacao e variam por item, nao justificando uma dimensao propria. Uma dim_payment so faria sentido se houvesse muitas variaveis de pagamento a explorar analiticamente.

7. ETL em Profundidade

O ETL e o processo que transforma os 9 CSVs brutos no star schema do Data Warehouse. Tem tres fases: Extract, Transform e Load.

7.1 Extract

A fase de extracao e a leitura dos 9 CSVs pelo Pentaho. Ja nesta fase identificamos os problemas a tratar no Transform: datas nulas em encomendas nao entregues, multiplos itens por encomenda, multiplas reviews por encomenda (ficamos com a mais recente), duplicados na geolocalizacao e categorias de produto em portugues.

7.2 Staging Area

A **staging area** e uma tabela temporaria em PostgreSQL onde colocamos todos os dados ja joinados mas ainda nao no formato do star schema. Serve como zona de trabalho intermedia. Porquê ter uma staging area e nao carregar diretamente do CSV para o star schema? Porque assim podemos validar a qualidade dos dados transformados antes de os carregar no DW definitivo, e e mais facil fazer debug se algo correr mal.

```
orders
+ order_items      (JOIN em order_id)
+ order_reviews    (JOIN em order_id - ficamos com a mais recente)
+ order_payments    (JOIN em order_id)
+ customers         (JOIN em customer_id)
+ sellers           (JOIN em seller_id via order_items)
+ products          (JOIN em product_id via order_items)
+ geolocation       (JOIN em zip_code_prefix - media das coords)
+ translations      (JOIN em product_category_name)
|
v
STAGING AREA (PostgreSQL - tabela temporaria)
-> dados validados e transformados
-> prontos para carga no star schema
```

7.3 Transform - Metricas Derivadas

Criamos campos que nao existem nas tabelas de origem mas que sao fundamentais para o projeto:

```
# delivery_delay_days - a metrica mais importante do projeto
delay = order_delivered_customer_date - order_estimated_delivery_date
# Positivo = atraso | Negativo = entregue antes do prazo

# Exemplo real do dataset:
# Compra: 2017-10-02 | Estimado: 2017-10-18 | Entregue: 2017-10-10
# delay = -8 dias -> entrega antecipada, cliente provavelmente satisfeito

# ds_negative_rev - o label para Q4
ds_negative_rev = 1 IF review_score <= 2 ELSE 0

# is_late_delivery - flag adicional para facilitar queries
is_late_delivery = 1 IF delay_days > 0 ELSE 0

# estimated_delivery_days - para Q5
estimated = order_estimated_delivery_date - order_purchase_timestamp
```

7.4 Tratamento de Nulos e Duplicados

Encomendas com order_status diferente de 'delivered' tem a data de entrega nula - são excluídas da analise de atraso mas mantidas para analise de volume. Reviews nulas são excluídas da analise de satisfação. Para a geolocalizacao, como o mesmo zip code aparece com coordenadas ligeiramente diferentes em múltiplos registos, calculamos a media e ficamos com um unico registo por zip code. Nomes de cidades sao normalizados para minusculas sem acentos.

7.5 SCD - Slowly Changing Dimensions

O conceito de **SCD** define o que fazer quando um atributo de uma dimensao muda ao longo do tempo. Por exemplo: um vendedor que em 2017 estava em Sao Paulo muda-se para o Rio de Janeiro em 2018.

SCD Type 1 - Sobrescrever (o que usamos)

O registo antigo e substituido pelo novo. Simples e eficiente - a tabela nao cresce. Perde-se o historico, mas no contexto do nosso projeto (dados historicos 2016-2018, sem updates reais) isso nao tem impacto analitico.

ANTES: sk=5, city=Sao Paulo
APOS: sk=5, city=Rio de Janeiro
<- SOBRESCREITO

SCD Type 2 - Manter historico

Cria um novo registo com o valor novo, mantendo o antigo com datas de validade. Preserva o historico completo mas a tabela cresce e as queries ficam mais complexas. Usaria-se se a analise temporal dos atributos fosse critica.

sk=5, SP, valid_to=2018, current=0
sk=9, RJ, valid_from=2018, current=1

7.6 Load e Automatizacao

No primeiro load, todos os dados historicos sao inseridos nas dimensoes e nos factos. Nos loads seguintes, a estrategia e incremental: o Pentaho guarda a data do ultimo load numa tabela de controlo e, na proxima execucao, so extrai encomendas com order_purchase_timestamp posterior a essa data. Para as dimensoes (SCD Type 1), verifica se a entidade ja existe - se sim, atualiza; se nao, insere. Para os factos, faz sempre append - nunca se atualizam factos historicos.


8. Os Dashboards

Desenhamos no figma uma ideia de como queremos que a nossa dash seja, destinados ao Sebastiao M. e a equipa de operacoes do Olist. Os dois primeiros estao no poster; os dois ultimos ficaram fora por questoes de espaco mas estao planeados e implementados.


8.1 Business Overview (Q1 + Q2)

Dashboard 1 - Business Overview: visao geral do negocio com filtro temporal e mapa interativo

Este dashboard da ao Sebastiao uma visao geral do estado do negocio. No topo estao os KPIs principais: total de encomendas (98.666), revenue bruto (R\$13.6M), ticket medio (R\$137), tempo medio de entrega (12 dias) e vendedores ativos (3.095). O grafico principal mostra **revenue e volume de encomendas ao longo do tempo** - responde a Q1. O utilizador usa o **filtro temporal no canto superior direito** (Last 30d, Last 90d, Full period, Custom) - esta e a **interacao temporal obrigatoria**. O **mapa do Brasil por estado** permite clicar para filtrar todos os graficos - esta e a **interacao geografica obrigatoria**.




8.2 Delivery Performance (Q2 + Q3)



Dashboard 2 - Delivery Performance: analise de atrasos, freight e ranking de vendedores

Os KPIs mostram: taxa de atraso global (6.4%), pior estado (AL com 21.7%), revenue em risco (R\$811K) e taxa de reviews negativas quando ha atraso (62%). O mapa usa circulos proporcionais ao numero de atrasos, clicavel para drill-down. O heatmap mostra padroes por dia da semana e mes. O grafico **Freight + delays -> negative reviews** responde visualmente a Q2. A tabela de **ranking de vendedores** responde a Q3, com colunas para Seller, State, Orders, Delay%, Score e Top Category.


8.3 Customer Satisfaction (adicional)



Dashboard 3 - Customer Satisfaction: distribuicao de reviews e categorias com mais reviews negativas

Mostra a distribuicao de review scores (64% de 5 estrelas, 16% negativas), o mapa de score medio por estado (verde = bom, vermelho = mau) e o ranking de **categorias com maior proporcao de reviews negativas**. As categorias 'office furniture' e 'fashion male clothing' lideram com 28% e 25% respetivamente. Util para o Sebastiao priorizar auditorias de vendedores.

8.4 Predictive Alerts (adicional - Q4 + Q5 + Q6)



Dashboard 4 - Predictive Alerts: encomendas em risco com recomendacoes automaticas

O dashboard mais inovador - implementa Q4 e Q5 de forma pratica. Os KPIs mostram encomendas de **alto risco (15)**, risco medio (12) e zona segura (23). A tabela de acao urgente lista cada encomenda com o estado, dias previstos, probabilidade de review negativa, cluster (de Q6), **acao recomendada e decisao final (ESCALATE / WATCH)**. E aqui que Q5 se torna prescritivo - o sistema nao so preve o risco como recomenda automaticamente a acao. A risk matrix e o mapa de encomendas em risco completam a visualizacao.

9. Dados Reais e Limitacoes

9.1 Distribuicao Real dos Dados

Conhecer os numeros reais do dataset torna as respostas mais concretas e credíveis na discussao.

Metrica	Valor real	Implicacao para o projeto
Encomendas entregues	~96% do dataset	As restantes 4% (invoiced, shipped) sao excluidas da analise de atraso mas mantidas para volume
Reviews negativas (1-2 estrelas)	~16% do total	Class imbalance em Q4 - justifica SMOTE e uso de F1/AUC-ROC em vez de accuracy
Distribuicao reviews	64% sao 5 estrelas, 19% sao 4 estrelas	Distribuicao muito assimetrica - confirma o problema do imbalance
Metodo de pagamento dominante	~80% cartao de credito, ~12% boleto	Boleto = referencia MB brasileira, nao requer cartao
Itens por encomenda	~89% tem 1 item, ~8% tem 2, ~4% tem 3+	Justifica granularidade ao nivel do item - maioria e 1:1 mas ha excecoes importantes
Estado dominante (vendedores)	SP = ~50% dos vendedores	Explica concentracao no mapa - centro economico do Brasil
Estado dominante (clientes)	SP = ~50% dos clientes	Coincide com concentracao de vendedores

9.2 O que e o Boleto?

O **boleto bancario** e um metodo de pagamento tipicamente brasileiro que aparece no campo payment_type do dataset. E equivalente a uma referencia Multibanco portuguesa: gera-se um documento (fisico ou digital) com um codigo de barras que pode ser pago num banco, numa loja ou online. Nao requer cartao de credito nem conta bancaria direta - o que o torna inclusivo para populacoes sem acesso a servicos bancarios tradicionais. Para o projeto, e relevante porque **encomendas pagas por boleto podem ter padroes de comportamento diferentes** (ex: maior propensao para cancelamento se o pagamento nao for confirmado).

9.3 Limitacoes Identificadas

O enunciado pede explicitamente para identificar problemas com os dados. Estas sao as limitacoes concretas do nosso projeto:

Limitacao	Impacto	Como mitigamos
Nao distinguimos se o atraso e culpa do vendedor ou da transportadora	Nao conseguimos responsabilizar com precisao	Mencionamos como limitacao - os dados nao permitem resolver
Encomendas sem review (nao toda a gente avalia)	Analise de satisfacao tem viés de selecao - quem avalia nao e representativo	Excluimos da analise de satisfacao, mantemos para volume

Dataset limitado a 2016-2018	Padroes podem estar desatualizados (pandemia, novas transportadoras)	Explicito nas conclusoes - resultados validos para o periodo
Zip codes sem geolocalizacao correspondente	Algumas encomendas ficam sem coordenadas para o mapa	Excluimos coordenadas mas mantemos cidade/estado
Categorias em portugues sem traducao completa	Algumas categorias ficam como 'unknown'	Usamos tabela de traducao fornecida + 'unknown' para o resto

10. Resultados Esperados

O enunciado exige uma seccao de 'Expected Results'. Estes sao os resultados que esperamos obter com o projeto concluido:

DW + OLAP (Q1, Q2, Q3) Mapa de atraso e satisfacao: identificar os estados e categorias com maior taxa de atraso e pior review score. Hipotese: estados do Norte e Nordeste do Brasil com maior distancia dos centros de distribuicao terao piores metricas. Impacto de freight e atraso: quantificar que o atraso tem peso relativo superior ao freight value na probabilidade de review negativa (coeficiente mais alto na regressao logistica). Ranking de vendedores: identificar que os vendedores com pior performance se concentram em estados sem infraestrutura logistica desenvolvida e vendem categorias de alto peso.	Data Mining (Q4, Q5, Q6) Classificador de review negativa: modelo com AUC-ROC > 0.75, onde freight_value, estimated_delivery_days e seller_state aparecem como top features por feature importance. Sistema de alertas: para encomendas com probabilidade > 70% de review negativa, disparar alerta automatico - reduzindo o impacto nas reviews em 20-30% nos casos tratados. Clusters de risco: emergir 3-5 clusters com perfis distintos (ex: alto risco = Norte + categorias pesadas + vendedor pequeno; baixo risco = SP + electronica + vendedor grande).
---	---

11. Perguntas Provaveis do Professor

A discussao dura 5 minutos. Para cada resposta: O QUE E - PORQUE ESCOLHEMOS - COMO IMPLEMENTAMOS.

? Qual a granularidade da fact_sales?	Um registo por item de encomenda. Assim analisamos por categoria e por vendedor de forma independente, mesmo quando uma encomenda tem multiplos itens de vendedores diferentes.
? Porque a dim_order esta separada?	Duas razoes: review_score e semi-aditivo (a soma nao faz sentido, so a media) e pertence a granularidade da encomenda, nao do item. Se ficasse na fact_sales, uma encomenda com 3 itens teria o mesmo review repetido 3 vezes, inflacionando medias.
? O que e SCD e que tipo usam?	Slowly Changing Dimension - o que fazer quando um atributo de uma dimensao muda (ex: vendedor muda de cidade). Usamos SCD Type 1 (overwrite) porque os dados sao historicos (2016-2018) e nao ha updates reais. Simplifica o ETL sem perder valor analitico.
? Star Schema ou Snowflake? Porquê Star?	Star Schema. O Snowflake normalizaria as dimensoes em sub-tabelas, o que poupa espaco mas aumenta o tempo de resposta e torna as queries mais complexas. Como os slides da professora dizem, 'using snowflakes is rarely justifiable' - as dimensoes sao sempre uma pequena parte do DW.
? O que sao surrogate keys e porquê usar?	

Sao chaves artificiais geradas pelo DW (sk_customer, etc.) independentes dos IDs do sistema de origem. Protegem o DW de mudancas nos sistemas de origem - se o Olist mudar o formato dos IDs, so a dimensao precisa de ser atualizada, o resto do DW nao e afetado.

? O que e ROLAP? Que tipo de OLAP usam?

ROLAP = Relational OLAP - modelo multidimensional sobre uma base de dados relacional. Usamos ROLAP: Tableau sobre PostgreSQL. MOLAP usaria uma BD propria para cubos multidimensionais - mais rapido mas rigido e quase obsoleto. Escolhemos ROLAP pela flexibilidade e integracao com PostgreSQL.

? O que sao drill-down e roll-up?

Drill-down desce na hierarquia de uma dimensao - do geral para o especifico (ex: ano -> mes -> dia). Roll-up sobe na hierarquia - do especifico para o geral. No nosso mapa, clicar num estado e um drill-down geografico. O filtro temporal que agrega por mes e um roll-up.

? Como distinguem Q4 (predictive) de Q5 (prescriptive)?

Q4 preve passivamente - devolve probabilidade de review negativa mas nao age. Q5 preve e age - quando o risco ultrapassa um threshold, dispara automaticamente uma recomendacao. Q5 fecha o ciclo analitico: nao so preve, decide e age.

? Para Q4, que modelo usam e porque?

Random Forest ou XGBoost - robustos com features mistas, interpretaveis por feature importance. Como reviews negativas sao ~16% do dataset (class imbalance), usamos SMOTE para oversampling e avaliamos com F1-score e AUC-ROC, nao accuracy.

? Como medem a associacao em Q2?

Correlacao de Spearman (dados nao normais) para confirmar relacao monotonica, depois regressao logistica para quantificar o peso relativo. Falamos sempre de 'associacao', nunca de 'causa' - correlacao nao implica causalidade.

? Que limitacoes tem o projeto?

Tres principais: nao conseguimos distinguir se o atraso e culpa do vendedor ou da transportadora; encomendas sem review introduzem vies de selecao na analise de satisfacao; o dataset e de 2016-2018 e os padroes podem estar desatualizados.

? Porque X clusters em Q6?

Ainda nao corremos o modelo. Vamos justificar empiricamente com elbow plot (inercia vs numero de clusters) e silhouette score. Nao e decisao arbitraria - e baseada nos dados.

12. Referencia Rapida - O que Saber de Cor

Componente	Resposta de 10 segundos	Detalhe critico
Dataset	Olist: 100K+ encomendas reais, Brasil, 2016-2018, 9 tabelas	27 estados, Kaggle, e-commerce B2B2C
Problema	Atrasos -> reviews negativas -> menos comissao	Olist nao controla logistica - so intermediario
Objetivo	Identificar, explicar e antecipar insatisfacao	DW para OLAP + DM para previsao e prescricao
Utilizador	Sebastiao M., Ops Manager do Olist	Gere performance de entrega e satisfacao
Granularidade	1 linha por item de encomenda (order_item)	Nao por encomenda - para analisar por categoria e vendedor
Fact table	price, freight, delay_days, review_score	delay_days = delivered - estimated (ETL)
Dimensoes	dim_date, customer, seller, product, order (5)	dim_order separada: review semi-aditivo, granularidade diferente

Star vs Snowflake	Usamos Star - dimensoes desnormalizadas	Snowflake poupa espaco mas e mais lento e complexo
Surrogate keys	sk * artificiais, independentes dos IDs de origem	Protegem o DW de mudancas nos sistemas de origem
OLAP type	ROLAP - Tableau sobre PostgreSQL relacional	MOLAP usaria BD propria para cubos - mais rigido
Operacoes OLAP	Drill-down (detalhar), Roll-up (agregar), Slice (filtrar 1 dim), Dice (filtrar N dims)	Mapa clicavel = drill-down; filtro temporal = slice/roll-up
Hierarquia dim_date	Ano -> Trimestre -> Mes -> Semana -> Dia -> Hora	Pre-calculada no ETL para acelerar queries Tableau
ETL	Pentaho -> Staging Area -> PostgreSQL	SCD Type 1 nas dims; append incremental nos factos
ds_negative_rev	Flag 0/1: 1 se review_score <= 2	Label do modelo preditivo Q4
Q4 vs Q5	Q4 preve (passivo); Q5 preve + age (ativo)	Q5 prescritivo porque decide e age apos previsao
Class imbalance Q4	Reviews negativas ~16% do dataset	SMOTE + F1-score + AUC-ROC (nao accuracy)
Q6 clusters	K-Means ou DBSCAN, numero pelo elbow plot	Decisive: informa decisoes estrategicas
Limitacao principal	Nao distinguimos causa do atraso (vendedor vs transportadora)	Os dados nao permitem resolver - mencionar na discussao

Guiaio dos 5 minutos:

30s Motivacao: 'Olist, 100K encomendas, atrasos -> reviews negativas -> ciclo vicioso com impacto financeiro direto.'
1min Big Questions: '3 DW (Q1 descritiva, Q2 diagnostica, Q3 sellers) + 3 DM (Q4 preditiva, Q5 prescritiva, Q6 clustering).'
1min Star Schema: 'Granularidade: item de encomenda. 5 dimensoes. dim_order separada porque review e semi-aditivo.'
1min Workflow + ETL: 'Pentaho -> PostgreSQL (ROLAP) -> Tableau + Python. SCD Type 1, loads incrementais.'
1min Mockups: '4 dashboards. Interacao temporal (filtro periodo) e geografica (mapa clicavel).'
30s Expected Results: 'O Sebastiao consegue ver tendencias, identificar risco e receber alertas automaticos antes que o cliente seja afetado. Revenue protegido estimado: R\$162K.'